

# DỰ ĐOÁN RỦI RO VỠ NỢ TÍN DỤNG VÀ ƯỚC LƯỢNG TỔN THẤT KỲ VỌNG BẰNG MÔ HÌNH PD-EAD-LGD

Trần Thái Ân – 250104001

**Tóm tắt** - Nghiên cứu này mở rộng bài toán dự đoán vỡ nợ thẻ tín dụng từ phân loại nhị phân sang ước lượng tổn thất tài chính kỳ vọng. Dữ liệu gồm 30.000 khách hàng, trong đó tỷ lệ vỡ nợ tháng tiếp theo là 22,12%. Random Forest cân bằng lớp được lựa chọn cho mục tiêu phát hiện rủi ro, đạt Recall 59,27%, F1-score 54,22% và ROC-AUC 0,779. Kết quả phân tích cho thấy trạng thái thanh toán gần nhất, mức trễ hạn lớn nhất và số kỳ từng trễ hạn là các biến quan trọng nhất. Để sử dụng xác suất vỡ nợ trong công thức tổn thất kỳ vọng, một mô hình cảnh báo sớm được hiệu chỉnh bằng sigmoid; xác suất trung bình sau hiệu chỉnh là 22,12%, gần trùng với tỷ lệ vỡ nợ thực tế. Linear Regression dự báo dư nợ kỳ gần nhất với  $R^2 = 0,903$  và được sử dụng như một EAD proxy. Trong kịch bản LGD 50%, tổng Expected Loss đạt 46,16 triệu đơn vị tiền tệ gốc; 10% khách hàng có Expected Loss cao nhất bao phủ 55,49% Actual Loss Proxy. Kết quả cho thấy khung PD-EAD-LGD cung cấp thứ tự ưu tiên quản trị rõ hơn so với nhãn vỡ nợ 0/1 đơn thuần.

**Từ khóa** - Credit Risk, Probability of Default, Random Forest, Probability Calibration, EAD Proxy, Expected Loss.

## I. GIỚI THIỆU

Đánh giá rủi ro vỡ nợ thẻ tín dụng thường được trình bày như một bài toán phân loại: khách hàng có vỡ nợ trong tháng tiếp theo hay không. Cách tiếp cận này hữu ích cho cảnh báo sớm nhưng chưa trả lời đầy đủ hai câu hỏi quản trị: xác suất vỡ nợ của từng khách hàng là bao nhiêu và tổ chức tín dụng có thể chịu thiệt hại ở mức nào. Một khách hàng có xác suất vỡ nợ cao nhưng dư nợ nhỏ có thể gây tổn thất thấp hơn khách hàng có xác suất trung bình nhưng dư nợ rất lớn.

Nghiên cứu được thực hiện theo hướng top-down với ba mục tiêu. Thứ nhất, nhận diện khách hàng có nguy cơ vỡ nợ và giải thích các yếu tố hành vi liên quan. Thứ hai, hiệu chỉnh xác suất vỡ nợ để xác suất dự báo phản ánh gần hơn tỷ lệ rủi ro quan sát được. Thứ ba, kết hợp xác suất vỡ nợ với dư nợ dự báo và tỷ lệ tổn thất giả định để ước lượng Expected Loss, từ đó xếp hạng khách hàng theo mức độ thiệt hại tài chính kỳ vọng.

Đóng góp chính của nghiên cứu là chuyển kết quả từ “ai có thể vỡ nợ” sang “khách hàng nào cần được ưu tiên quản trị trước”. Cách tiếp cận này giúp mô hình có ý nghĩa thực tiễn hơn đối với phân bổ nguồn lực giám sát, nhắc nợ và thu hồi nợ.

## II. NGHIÊN CỨU LIÊN QUAN

Nghiên cứu sử dụng bộ dữ liệu *Default of Credit Card Clients* do Yeh và Lien xây dựng, gồm lịch sử hạn mức, dư nợ, thanh toán và trạng thái trễ hạn của khách hàng thẻ tín dụng [1], [2]. Bộ dữ liệu này được sử dụng rộng rãi để so sánh các kỹ thuật

dự đoán xác suất vỡ nợ.

Random Forest là mô hình tổ hợp nhiều cây quyết định, có khả năng mô tả quan hệ phi tuyến và tương tác giữa các biến mà không yêu cầu giả định phân phối chặt chẽ [3]. Tuy nhiên, mô hình phân loại có khả năng xếp hạng tốt chưa chắc tạo ra xác suất đáng tin cậy. Khi xác suất được dùng trực tiếp trong công thức tài chính, probability calibration trở thành bước cần thiết [4].

Trong quản trị rủi ro tín dụng, tổn thất kỳ vọng thường được mô tả theo ba thành phần: Probability of Default (PD), Exposure at Default (EAD) và Loss Given Default (LGD) [5]. Dữ liệu nghiên cứu không chứa EAD và LGD thực tế, vì vậy BILL\_AMT1 đương được sử dụng như EAD proxy và LGD được xây dựng dưới dạng các kịch bản giả định. Kết quả do đó phản ánh một khung phân tích mở rộng, không phải mô hình đo lường tổn thất theo chuẩn triển khai ngân hàng.

## III. PHƯƠNG PHÁP NGHIÊN CỨU

### A. Dữ liệu và tiền xử lý

Bộ dữ liệu gồm 30.000 khách hàng, 23 biến đầu vào và một biến mục tiêu ghi nhận trạng thái vỡ nợ trong tháng tiếp theo. Dữ liệu không có giá trị thiếu, dòng trùng hoặc ID trùng. Các mã ít phổ biến ở EDUCATION và MARRIAGE được gộp vào nhóm “Khác/không xác định”. Dữ liệu gốc được giữ cho phân tích mô tả; trong dữ liệu mô hình, các trạng thái PAY\_x nhỏ hơn hoặc bằng 0 được quy về 0, đại diện cho không trễ hạn.

Dữ liệu được chia 70% cho huấn luyện và 30% cho kiểm tra, có phân tầng theo biến vỡ nợ. Việc chia tập được cố định bằng *random\_state=42* để bảo đảm khả năng tái lập.

### B. Phân tích dữ liệu và tạo đặc trưng

Ngoài các biến gốc, nghiên cứu xây dựng thêm các biến hành vi: số kỳ từng trễ hạn, mức trễ hạn lớn nhất, tỷ lệ thanh toán trên dư nợ, tỷ lệ sử dụng hạn mức, dư nợ trung bình, khoản thanh toán trung bình và xu hướng dư nợ. Các biến này giúp mô tả mức độ tích lũy rủi ro thay vì chỉ xem từng tháng riêng lẻ.

### C. Mô hình xác suất vỡ nợ

Bốn mô hình được so sánh: Dummy Classifier, Logistic Regression cân bằng lớp, Random Forest gốc và Random Forest cân bằng lớp. Việc đánh giá sử dụng Accuracy, Precision, Recall, F1-score, ROC-AUC và PR-AUC. Random Forest cân bằng lớp được chọn cho mục tiêu phát hiện rủi ro vì tăng Recall lớp vỡ nợ, dù Accuracy giảm so với Random Forest gốc. Khung Expected Loss sử dụng một mô hình PD cảnh báo sớm chỉ nhận thông tin từ các kỳ cũ hơn, đồng bộ với thời điểm của mô hình EAD proxy và hạn chế target leakage. Xác suất

PD được hiệu chỉnh bằng sigmoid thông qua cross-validation.

#### D. Mô hình EAD proxy và Expected Loss

BILL\_AMT1 được dự báo từ lịch sử BILL\_AMT2 đến BILL\_AMT6 cùng các biến thanh toán tương ứng. Bốn phương án được so sánh: Median baseline, Linear Regression, Random Forest Regressor và HistGradientBoosting. Mô hình được lựa chọn theo MAE trung bình qua cross-validation, sau đó đánh giá trên tập kiểm tra bằng MAE, RMSE và  $R^2$ .

Tổn thất kỳ vọng của khách hàng  $i$  được tính theo:


$$EL_i = PD_i \times EAD_i \times LGD_i. \quad (1)$$

Ba kịch bản LGD được sử dụng gồm 30%, 50% và 70%. Để đánh giá khả năng ưu tiên, khách hàng được xếp hạng theo Expected Loss và đối chiếu tỷ lệ Actual Loss Proxy được bao phủ trong các nhóm top 10%, 20%, 30% và 50%.

### IV. KẾT QUẢ VÀ THẢO LUẬN


#### A. Phân tích hành vi và hạn mức tín dụng

Tỷ lệ vỡ nợ toàn bộ dữ liệu là 22,12%. Lịch sử trễ hạn thể hiện mối liên hệ rõ nhất với biến mục tiêu. Nhóm chưa từng trễ hạn có tỷ lệ vỡ nợ 11,71%; tỷ lệ này tăng lên 29,82% khi khách hàng từng trễ hạn một kỳ, 50,87% ở ba kỳ và 70,32% ở sáu kỳ. Kết quả phản ánh một ngưỡng rủi ro quan sát được khi trễ hạn tích lũy, nhưng không đủ để kết luận quan hệ nhân quả hay cơ chế tâm lý.



Hình 1: Tỷ lệ vỡ nợ theo số kỳ từng trễ hạn.

Hạn mức tín dụng cũng có quan hệ nghịch với tỷ lệ vỡ nợ. Nhóm hạn mức thấp nhất có tỷ lệ vỡ nợ 31,79%, trong khi nhóm cao nhất là 13,80%. Hạn mức trung vị của nhóm vỡ nợ là 90.000, thấp hơn mức 150.000 ở nhóm không vỡ nợ. Tuy nhiên, hạn mức thấp có thể đồng thời phản ánh thu nhập, lịch sử tín dụng và chính sách cấp hạn mức; vì vậy không nên diễn giải đây là nguyên nhân trực tiếp gây vỡ nợ.



Hình 2: Tỷ lệ vỡ nợ theo nhóm hạn mức tín dụng.

#### B. Hiệu suất mô hình phân loại


Baseline luôn dự đoán không vỡ nợ đã đạt Accuracy 77,88% do dữ liệu mất cân bằng. Điều này cho thấy Accuracy khoảng 80% không đủ để chứng minh mô hình hữu ích. Random Forest gốc đạt Accuracy 81,64% nhưng Recall lớp vỡ nợ chỉ 35,01%. Random Forest cân bằng lớp giảm Accuracy xuống 77,86% nhưng tăng Recall lên 59,27%, F1-score 54,22% và ROC-AUC 0,779.

Bảng 1: So sánh các mô hình phân loại.

| Mô hình           | Acc.  | Recall | F1    | AUC   |
|-------------------|-------|--------|-------|-------|
| RF cân bằng       | 77,86 | 59,27  | 54,22 | 0,779 |
| RF gốc            | 81,64 | 35,01  | 45,76 | 0,777 |
| Logistic cân bằng | 74,41 | 59,97  | 50,91 | 0,754 |
| Baseline          | 77,88 | 0,00   | 0,00  | 0,500 |

Random Forest cân bằng lớp được chọn vì mục tiêu nghiên cứu ưu tiên giảm bỏ sót khách hàng vỡ nợ. Kết quả này thể hiện sự đánh đổi giữa Recall và số lượng cảnh báo nhầm; ngưỡng quyết định thực tế cần được tối ưu bằng chi phí nghiệp vụ thay vì mặc định ở 0,5.


Permutation importance cho thấy PAY\_0 là biến quan trọng nhất, tiếp theo là mức trễ hạn lớn nhất, số kỳ trễ hạn, tỷ lệ thanh toán dư nợ và tỷ lệ sử dụng hạn mức. Các biến hành vi chiếm ưu thế so với đặc điểm nhân khẩu học, phù hợp với kết quả phân tích mô tả.



Hình 3: Các yếu tố quan trọng đối với dự báo vỡ nợ.

### C. Hiệu chỉnh xác suất PD

PD thô của mô hình cảnh báo sớm có giá trị trung bình 41,10%, cao hơn đáng kể tỷ lệ vỡ nợ thực tế 22,12%. Sau sigmoid calibration, PD trung bình giảm còn 22,12%; Brier score giảm từ 0,1819 xuống 0,1442 và log loss giảm từ 0,5488 xuống 0,4529. ROC-AUC gần như không thay đổi, vì calibration điều chỉnh độ tin cậy của xác suất thay vì thay đổi mạnh thứ tự xếp hạng.



Hình 4: Độ hiệu chỉnh xác suất vỡ nợ theo phân vị.


Ở phân vị rủi ro cao nhất, PD sau hiệu chỉnh trung bình là 61,99%, gần với tỷ lệ vỡ nợ thực tế 62,22%. Kết quả cho phép sử dụng PD đã hiệu chỉnh trong công thức Expected Loss hợp lý hơn PD thô.

### D. Dự báo EAD proxy

Linear Regression cho kết quả tốt nhất với MAE 8.659, RMSE 22.889 và  $R^2 = 0,903$ . Random Forest Regressor đạt  $R^2 = 0,900$ , không cải thiện so với mô hình tuyến tính. Điều này cho thấy dư nợ kỳ gần nhất có tính dự trù mạnh từ lịch sử dư nợ các kỳ trước.

Bảng 2: Kết quả dự báo EAD proxy.

| Mô hình                 | MAE    | RMSE   | $R^2$  |
|-------------------------|--------|--------|--------|
| Linear Regression       | 8.659  | 22.889 | 0,903  |
| Random Forest Regressor | 8.721  | 23.234 | 0,900  |
| HistGradientBoosting    | 9.001  | 22.965 | 0,903  |
| Median baseline         | 44.934 | 79.165 | -0,156 |



Hình 5: Dư nợ thực tế và EAD proxy dự báo.

BILL\_AMT1 chỉ đại diện cho dư nợ kỳ gần nhất, không phải EAD thực tế tại thời điểm vỡ nợ. Vì vậy,  $R^2$  cao phản ánh khả năng dự báo proxy này, không thể diễn giải như độ chính xác của EAD trong triển khai tín dụng thực tế.


### E. Expected Loss và khả năng ưu tiên khách hàng

Tổng Expected Loss đạt 27,70 triệu ở kịch bản LGD 30%, 46,16 triệu ở LGD 50% và 64,63 triệu ở LGD 70%. Trong kịch bản cơ sở LGD 50%, Actual Loss Proxy là 50,05 triệu; tổng Expected Loss tương đương 92,24% giá trị proxy quan sát. Sự gần nhau ở cấp tổng không đồng nghĩa dự báo từng khách hàng đều chính xác, nhưng cho thấy mô hình không còn phóng đại mạnh tổn thất sau calibration.

Bảng 3: Expected Loss theo kịch bản LGD.

| LGD | Expected Loss | Actual Loss Proxy |
|-----|---------------|-------------------|
| 30% | 27,70 triệu   | 30,03 triệu       |
| 50% | 46,16 triệu   | 50,05 triệu       |
| 70% | 64,63 triệu   | 70,07 triệu       |

Khả năng tập trung tổn thất là kết quả thực tiễn nổi bật nhất. Top 10% khách hàng theo Expected Loss bao phủ 55,49% Actual Loss Proxy; top 20% bao phủ 73,55%, top 30% bao phủ 84,05% và top 50% bao phủ 95,18%. Như vậy, tổ chức tín dụng có thể tập trung nguồn lực vào một nhóm khách hàng tương đối nhỏ nhưng chứa phần lớn thiệt hại kỳ vọng.



Hình 6: Khả năng tập trung tổn thất theo Expected Loss.

Expected Loss không chỉ ưu tiên khách hàng có PD cao nhất. Một khách hàng có PD trung bình nhưng EAD lớn vẫn có thể đứng ở nhóm ưu tiên cao. Do đó, khung PD-EAD-LGD bổ sung góc nhìn tài chính mà phân loại nhị phân không thể hiện.

## V. KẾT LUẬN VÀ HẠN CHẾ

Nghiên cứu cho thấy hành vi thanh toán, đặc biệt trạng thái thanh toán gần nhất và mức độ tích lũy trễ hạn, là tín hiệu quan trọng nhất đối với rủi ro vỡ nợ. Random Forest cân bằng lớp phù hợp hơn Random Forest gốc cho mục tiêu phát hiện khách hàng rủi ro vì Recall tăng từ 35,01% lên 59,27%, dù Accuracy giảm. Kết quả cũng cho thấy xác suất mô hình cần được hiệu chỉnh trước khi sử dụng trong công thức tổn thất.

Việc kết hợp PD đã calibration với EAD proxy và LGD giả định giúp chuyển mô hình từ dự đoán nhãn sang xếp hạng tổn

thất kỳ vọng. Top 10% khách hàng theo Expected Loss bao phủ hơn một nửa Actual Loss Proxy, qua đó cho thấy tiềm năng hỗ trợ phân bổ nguồn lực quản trị rủi ro.

Nghiên cứu có bốn hạn chế chính. Thứ nhất, dữ liệu chỉ có sáu kỳ lịch sử và một nhãn vỡ nợ tháng tiếp theo, không đủ để dự báo chuỗi dư nợ dài hạn. Thứ hai, BILL\_AMT1 là EAD proxy, không phải dư nợ thực tế tại thời điểm vỡ nợ. Thứ ba, dữ liệu không có tài sản bảo đảm, số tiền thu hồi hoặc chi phí thu hồi, nên LGD chỉ là kịch bản giả định. Thứ tư, feature importance và các biểu đồ mô tả phản ánh mối liên hệ thống kê, không chứng minh quan hệ nhân quả.

Các nghiên cứu tiếp theo nên sử dụng dữ liệu theo thời gian dài hơn, EAD và LGD thực tế, tối ưu ngưỡng quyết định theo chi phí và đánh giá mô hình trên tập dữ liệu ngoài mẫu hoặc giai đoạn thời gian khác.

## VI. TÀI LIỆU THAM KHẢO

- [1] I.-C. Yeh and C.-H. Lien, “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients,” *Expert Systems with Applications*, vol. 36, no. 2, pp. 2473–2480, 2009.
- [2] UCI Machine Learning Repository, “Default of Credit Card Clients Dataset.”
- [3] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [4] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proceedings of the 22nd International Conference on Machine Learning*, 2005.
- [5] Basel Committee on Banking Supervision, *International Convergence of Capital Measurement and Capital Standards*, Bank for International Settlements, 2006.
- [6] J. Gathergood, “Self-control, financial literacy and consumer over-indebtedness,” *Journal of Economic Psychology*, vol. 33, no. 3, pp. 590–602, 2012.
- [7] S. E. Lea, P. Webley, and C. M. Walker, “Psychological factors in consumer debt: Money management, economic socialization, and credit use,” *Journal of Economic Psychology*, vol. 16, no. 4, pp. 681–701, 1995.